

Uplift Modeling с последовательностью поведения клиента

Оценка приростного эффекта клиентских коммуникаций: классические CatBoost-learner'ы против Transformer на сырых чеках

Галиб Байрамов

Продуктовый аналитик, Т-Банк · маркетинговая аналитика, привлечение B2B

ИТМО AI Talent Hub · Junior ML Contest · 2026




иллюстрация: прирост эффекта коммуникации

Почему я выбрал эту задачу

Профессиональный опыт → исследовательский вопрос → самостоятельная проверка на открытых данных

Профессиональный контекст

Product Analyst, Т-Банк
Команда роста маркетинговой аналитики
Привлечение B2B-клиентов

- оценка маркетинговых запусков
- сегментация клиентов
- A/B-тесты
- продуктовые метрики



Возникший вопрос

Средний эффект A/B-теста показывает, работает ли коммуникация в целом, но не отвечает, какому клиенту она помогла.

Можно ли оценить индивидуальный эффект коммуникации?



Самостоятельное исследование

Открытые данные X5 RetailHero
Uplift-моделирование
T-Learner, X-Learner, Transformer

Профессиональная задача стала мотивацией для самостоятельного ML-исследования.

Проект выполнен на открытых данных X5 RetailHero. Данные, код и внутренние результаты Т-Банка не использовались.

Бизнес-проблема

Коммуникация стоит денег — обращаться нужно к тем, кто изменит поведение именно благодаря ей

Стоимость и риск

Отправка SMS стоит денег и может раздражать клиента, поэтому обращаться нужно не ко всем, а к тем, кому это действительно поможет.

Отклик — это не прирост

Модель отклика находит тех, кто и так с высокой вероятностью купит. Из-за этого она выбирает не тех, кому нужна коммуникация, а тех, кто обошёлся бы и без неё.

Причинная оценка

Значит, вместо вероятности покупки нужно оценивать, изменится ли поведение клиента именно благодаря коммуникации.

Цель

Тогда при фиксированном бюджете рассылки можно получить максимальный прирост конверсий, а не просто максимум откликов.

X5 RetailHero: данные и постановка

Реальный, публичный датасет — потоковая обработка 4.4 ГБ без загрузки в память целиком

400 162

клиента

45.8 млн строк истории покупок
до кампании

200 039

с известным откликом

группы с коммуникацией и без —
примерно поровну (~50/50)

+3.3 п.п.

средний эффект

разница отклика между
группами — точка отсчёта для
всех моделей

11.2%

утечка устранена

first_redeem_date после отсечки
— цензурировано

Находка: утечка в официальном эталонном решении

Поле first_redeem_date простирается на 8 месяцев дальше окна истории покупок (отсечка 2019-03-18) — значит, оно частично описывает события ПОСЛЕ коммуникации. Официальное решение соревнования использует его «как есть», поэтому в этом проекте оно цензурировано.

Классические uplift-модели

Четыре подхода, один и тот же train/val/holdout сплит и одни и те же метрики

0 · Random targeting

Случайный порядок клиентов — не модель, а точка отсчёта: любая рабочая модель должна её обыграть.

1 · Response CatBoost

Предсказывает $P(Y=1|X)$ — вероятность покупки без учёта коммуникации, а значит, повторяет ту же ошибку, о которой шла речь на слайде 3.

2 · T-Learner


Обучает две отдельные CatBoost-модели на группах с коммуникацией и без, а прирост считает как разницу их прогнозов: $\tau(x) = \mu_1(x) - \mu_0(x)$.

3 · X-Learner

4-стадийная реализация (Kunzel et al., 2019) — не разность прогнозов, а отдельные модели эффекта с взвешиванием по вероятности коммуникации (propensity).

Transformer: shared representation, two heads

Обязательная модель проекта — работает на сырой последовательности чеков клиента



Единица последовательности — чек, не товарная позиция

Сравнил распределения длин по трём уровням: на товарном истории оказались слишком длинными (p95=312, max=2513) — поэтому выбрал чек: он компактнее (p95=54) и при этом сохраняет реальную гранулярность похода в магазин.

Результаты на отложенной выборке (n = 40 011)


Единая метрика для всех моделей: src/uplift_metrics.py, 9 unit-тестов

Qini/AUUC: 0 — модель не лучше случайного порядка; больше — точнее находит нужных клиентов; отрицательное — модель вредит

Модель	Qini	AUUC	uplift@30%
X-Learner	0.0042	0.0125	0.0755
T-Learner	0.0037	0.0120	0.0639
Transformer	0.0017	0.0100	0.0481
Random	0.0007	0.0090	0.0374
Response CatBoost	-0.0015	0.0068	0.0219


Главный вывод

Порядок X-Learner > T-Learner > Transformer > Random > Response одинаков по всем трём метрикам — не случайность одного показателя. Модель отклика значимо ХУЖЕ случайного распределения: весь ДИ Qini отрицательный.



Бизнес-эффект (сценарий) и A/B-тест

Офлайн Qini/AUUC — не доказательство реального бизнес-эффекта



Сценарий, не факт

Чтобы перевести ранжирование в деньги, я задал иллюстративные допущения — маржа 300₽, стоимость SMS 5₽. Это метод, а не факты X5 или Т-Банка.

Лучший результат

При этих допущениях наибольший ожидаемый эффект даёт X-Learner — на охвате примерно 57% аудитории.

Перед внедрением

Офлайн-метрики этого не доказывают, поэтому нужен онлайн A/B-эксперимент с защитными метриками и оценкой минимального эффекта.

Выводы и ограничения

Ранжирование моделей согласовано по всем метрикам, оба ключевых вывода подтверждены доверительными интервалами

Ранжирование

X-Learner > T-Learner > Transformer > Random > Response — согласовано по Qini, AUUC, uplift@30%.

Отклик вреден

Доверительный интервал Qini для модели отклика целиком отрицательный — значит, она не просто не помогает, а систематически хуже случайного распределения.

Transformer уступает

ДИ не пересекает ноль, значит, модель значимо лучше случайного распределения — но при этом CPU-бюджете обучения всё же уступает табличным моделям.

Дальше

Онлайн A/B-эксперимент, большой бюджет обучения Transformer, MLOps-пайплайн для продакшна.